

JURADO ASIGNADO:

Presidente: Dr...

Vocal: Dra....

Secretario: Dr....

Suplente: Dra....

Suplente: Dr....

DIRECTORA DE TESIS:

Dra. Helena M. Gómez Adorno



Esta obra está bajo una Licencia **Atribución/Reconocimiento-NoComercial-SinDerivados 4.0 Internacional** (CC BY-NC-ND 4.0).

Usted es libre de compartir, copiar y redistribuir el material en cualquier medio o formato, bajo los siguientes términos: debe otorgar el crédito correspondiente al autor, no puede utilizar el material con fines comerciales y, si transforma o crea a partir del material, no puede distribuir el material modificado.

Lo anterior sin perjuicio de lo establecido en la Legislación Universitaria de la Universidad Nacional Autónoma de México.

Para ver una copia de esta licencia, visite

<https://creativecommons.org/licenses/by-nc-nd/4.0/legalcode.es>

© Jorge Esteban Mendoza Ortiz

Ciudad de México, 2026.

Dedicatorias....

Agradecimientos

“Un individuo solo, sólo no puede
transcender.”

Carlos Salinas de Gortari

Ciudad Universitaria, 2026

Índice general

Índice general	vii
Índice de figuras	ix
Índice de tablas	xi
Índice de listados	xiii
Resumen	xiv
Summary	xv
1. Introducción	1
1.1. Motivación	1
1.2. Objetivos	1
1.3. Hipótesis	1
1.4. Preguntas de investigación	1
1.5. Contribución	1
1.6. Organización de la tesis	1
2. Marco teórico	3
2.1. Fundamentos de recuperación de información	3
2.1.1. El problema de la recuperación de información	3
2.1.2. El principio de ordenación por probabilidad (PRP)	3
2.2. Modelos de recuperación de primera etapa	3
2.2.1. Modelos léxicos probabilísticos: del BIM a BM25	3
2.2.2. Representaciones dispersas aprendidas (SPLADE)	3
2.2.3. Representaciones densas y codificadores duales	3
2.3. Reordenamiento neuronal	3
2.3.1. La arquitectura en cascada: recuperación y reordenamiento	3
2.3.2. Cross-encoders	3
2.4. Fusión de rangos	3
2.4.1. Formalización	3
2.4.2. Métodos basados en puntuaciones (CombMNZ)	3
2.4.3. Métodos posicionales (BordaFuse, RRF, ISR)	3
2.4.4. Comparaciones por pares y modelos de usuario (Condorcet, RBC)	3
2.5. Evaluación en recuperación de información	3
2.5.1. Métricas de evaluación	3
2.5.2. Pruebas de significancia estadística	3

3. Estado del arte	5
3.1. Líneas base de recuperación: de BM25 a los modelos neuronales modernos . . .	5
3.1.1. Modelos léxicos: BM25 y variantes modernas	5
3.1.2. Codificadores duales multilingües	5
3.1.3. Modelos multifuncionales y dispersos aprendidos (BGE-M3, SPLADE) .	5
3.1.4. Interacción tardía (de ColBERT a jina-colbert-v2)	5
3.2. Reordenamiento neuronal en la literatura	5
3.2.1. Cross-encoders (monoBERT, monoT5, bge-reranker-v2-m3)	5
3.2.2. Rerankers listwise con LLMs (RankGPT, jina-reranker-v3)	5
3.3. Fusión de rangos en la literatura	5
3.3.1. Los métodos clásicos	5
3.3.2. Fusión léxico-semántica en la era neuronal	5
3.3.3. Fusión interna del modelo vs. fusión externa de listas (BGE-M3)	5
3.4. Benchmarks de IR y el español	5
3.4.1. De TREC a MS MARCO y BEIR	5
3.4.2. Benchmarks multilingües y particularidades del español	5
3.4.3. MessIRve	5
3.5. Posicionamiento de esta tesis	5
4. Metodología	7
4.1. El conjunto de datos MessIRve	7
4.1.1. Estadísticas del conjunto de datos	8
4.2. Sistema de recuperación	10
4.3. Algoritmos de fusión	10
4.4. Diseño experimental	10
4.4.1. Experimento 1: fusión vs. modelos individuales	10
4.4.2. Experimento 2: comparación de algoritmos de fusión	10
4.4.3. Experimento 3: fusión vs. reordenamiento neuronal	10
4.4.4. Experimento 4: modelos abiertos vs. propietarios	10
5. Resultados experimentales	13
5.1. Experimento 1: fusión vs. modelos individuales	13
5.2. Experimento 2: comparación de algoritmos de fusión	13
5.3. Experimento 3: fusión vs. reordenamiento neuronal	13
5.4. Experimento 4: modelos abiertos vs. propietarios	13
5.5. Análisis de complementariedad léxico-semántica	13
6. Conclusiones y trabajo futuro	15
6.1. Conclusiones finales	15
6.2. Contribuciones del trabajo	15
6.3. Trabajo futuro	15
Bibliografía	17

Índice de figuras

4.1. Arquitectura del sistema de recuperación. Los documentos provienen del corpus de la Wikipedia en español (eswiki) y las consultas y los documentos relevantes, del conjunto de datos MessIRve. La fusión de rangos y el reordenamiento neuronal se evalúan como alternativas sobre los candidatos del módulo de recuperación.	11
--	----

Índice de tablas

4.1. Estadísticas de las particiones del subconjunto <code>full</code> de MessIRve (versión 1.2). Las filas son juicios de relevancia (pares consulta–documento); las demás columnas son conteos de elementos únicos: un documento es un párrafo de la Wikipedia en español y un artículo es el artículo que lo contiene.	9
4.2. Longitud en palabras de las consultas y de los documentos. En los documentos, las palabras se cuentan sobre el título y el texto, igual que en el sistema de recuperación. Las consultas y los documentos relevantes provienen del subconjunto <code>full</code> de MessIRve (versión 1.2); el corpus, del volcado de la Wikipedia en español de abril de 2024.	9
4.3. Distribución del número de documentos relevantes por consulta. Los porcentajes se calculan sobre las consultas de cada partición del subconjunto <code>full</code> de MessIRve (versión 1.2); una consulta puede tener más de un documento relevante.	10

Índice de listados

4.1. Ejemplo de una instancia del conjunto de datos MessIRve	8
--	---

Evaluación de la fusión de rangos (*rank fusion*) frente a modelos de reordenamiento neuronal (*neural reranking*) en la recuperación de información en español: un análisis con modelos abiertos sobre el conjunto de datos MessIRve

Tesis de Licenciatura

Jorge Esteban Mendoza Ortiz

Licenciatura en Matemáticas Aplicadas
Universidad Nacional Autónoma de México

Resumen

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Vestibulum viverra porta diam, quis placerat leo blandit sit amet. Nam enim sem, pellentesque vel mi quis, condimentum mattis lectus. Cras in sapien suscipit, ullamcorper turpis eget, venenatis quam. Maecenas non ipsum auctor nisi venenatis volutpat sit amet at lorem. Donec at dignissim eros, vitae maximus mauris. Nullam et orci mattis, volutpat nisi nec, condimentum leo. Morbi scelerisque tristique imperdiet.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Quisque interdum dolor non aliquet rutrum. Duis congue mauris ut urna rutrum, in vulputate metus volutpat. Phasellus dui dui, laoreet nec purus eu, auctor feugiat libero. Aliquam placerat tellus lacinia, pulvinar lorem ac, faucibus justo. Morbi interdum odio ligula, sed mattis nisi pulvinar nec. Aenean dapibus imperdiet nulla placerat tristique. Maecenas consectetur dui a nibh ullamcorper sollicitudin. Integer vestibulum ante quis metus vestibulum, sollicitudin auctor est blandit. Morbi bibendum ultricies dignissim. Maecenas sodales risus ut purus congue blandit. Proin pretium augue et dignissim vulputate.

Morbi nulla nunc, feugiat fermentum nisl vitae, sollicitudin tincidunt leo. Duis bibendum ipsum justo, lacinia sodales lorem rutrum et. In mattis varius tortor, id placerat erat imperdiet a. Curabitur convallis dui non posuere facilisis. Aenean varius mauris eu semper viverra. Nulla semper eget sem at malesuada. Integer porta varius ligula non egestas. Donec dignissim quam sit amet felis tincidunt, vel scelerisque elit placerat. Integer ornare felis et sem euismod suscipit. Curabitur a nisi ac metus ultricies laoreet in at nunc. Maecenas auctor libero sit amet rutrum consectetur. Pellentesque sit amet accumsan metus, venenatis vulputate erat. Cras egestas vel turpis vitae dapibus.

Title
MSc Thesis

Nombre Alumno
Posgrado en Ciencia e Ingeniería de la Computación
Universidad Nacional Autónoma de México

Summary

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Vestibulum viverra porta diam, quis placerat leo blandit sit amet. Nam enim sem, pellentesque vel mi quis, condimentum mattis lectus. Cras in sapien suscipit, ullamcorper turpis eget, venenatis quam. Maecenas non ipsum auctor nisi venenatis volutpat sit amet at lorem. Donec at dignissim eros, vitae maximus mauris. Nullam et orci mattis, volutpat nisi nec, condimentum leo. Morbi scelerisque tristique imperdiet.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Quisque interdum dolor non aliquet rutrum. Duis congue mauris ut urna rutrum, in vulputate metus volutpat. Phasellus dui dui, laoreet nec purus eu, auctor feugiat libero. Aliquam placerat tellus lacinia, pulvinar lorem ac, faucibus justo. Morbi interdum odio ligula, sed mattis nisi pulvinar nec. Aenean dapibus imperdiet nulla placerat tristique. Maecenas consectetur dui a nibh ullamcorper sollicitudin. Integer vestibulum ante quis metus vestibulum, sollicitudin auctor est blandit. Morbi bibendum ultricies dignissim. Maecenas sodales risus ut purus congue blandit. Proin pretium augue et dignissim vulputate.

Morbi nulla nunc, feugiat fermentum nisl vitae, sollicitudin tincidunt leo. Duis bibendum ipsum justo, lacinia sodales lorem rutrum et. In mattis varius tortor, id placerat erat imperdiet a. Curabitur convallis dui non posuere facilisis. Aenean varius mauris eu semper viverra. Nulla semper eget sem at malesuada. Integer porta varius ligula non egestas. Donec dignissim quam sit amet felis tincidunt, vel scelerisque elit placerat. Integer ornare felis et sem euismod suscipit. Curabitur a nisi ac metus ultricies laoreet in at nunc. Maecenas auctor libero sit amet rutrum consectetur. Pellentesque sit amet accumsan metus, venenatis vulputate erat. Cras egestas vel turpis vitae dapibus.

Capítulo 1

Introducción

Aquí va la introducción del capítulo (motivación, objetivos, hipótesis, preguntas de investigación, contribución y organización de la tesis).

1.1. Motivación

1.2. Objetivos

1.3. Hipótesis

1.4. Preguntas de investigación

1.5. Contribución

1.6. Organización de la tesis

Capítulo 2

Marco teórico

En este capítulo se describen los conceptos y términos que se utilizarán en el desarrollo de esta tesis.

2.1. Fundamentos de recuperación de información

2.1.1. El problema de la recuperación de información

2.1.2. El principio de ordenación por probabilidad (PRP)

2.2. Modelos de recuperación de primera etapa

2.2.1. Modelos léxicos probabilísticos: del BIM a BM25

2.2.2. Representaciones dispersas aprendidas (SPLADE)

2.2.3. Representaciones densas y codificadores duales

2.3. Reordenamiento neuronal

2.3.1. La arquitectura en cascada: recuperación y reordenamiento

2.3.2. Cross-encoders

2.4. Fusión de rangos

2.4.1. Formalización

2.4.2. Métodos basados en puntuaciones (CombMNZ)

2.4.3. Métodos posicionales (BordaFuse, RRF, ISR)

2.4.4. Comparaciones por pares y modelos de usuario (Condorcet, RBC)

2.5. Evaluación en recuperación de información

2.5.1. Métricas de evaluación

2.5.2. Pruebas de significancia estadística

Capítulo 3

Estado del arte

En este capítulo se presenta un panorama del estado del arte y el posicionamiento de esta tesis.

3.1. Líneas base de recuperación: de BM25 a los modelos neuronales modernos

3.1.1. Modelos léxicos: BM25 y variantes modernas

3.1.2. Codificadores duales multilingües

3.1.3. Modelos multifuncionales y dispersos aprendidos (BGE-M3, SPLADE)

3.1.4. Interacción tardía (de ColBERT a jina-colbert-v2)

3.2. Reordenamiento neuronal en la literatura

3.2.1. Cross-encoders (monoBERT, monoT5, bge-reranker-v2-m3)

3.2.2. Rerankers listwise con LLMs (RankGPT, jina-reranker-v3)

3.3. Fusión de rangos en la literatura

3.3.1. Los métodos clásicos

3.3.2. Fusión léxico-semántica en la era neuronal

3.3.3. Fusión interna del modelo vs. fusión externa de listas (BGE-M3)

3.4. Benchmarks de IR y el español

3.4.1. De TREC a MS MARCO y BEIR

3.4.2. Benchmarks multilingües y particularidades del español

3.4.3. MessIRve

3.5. Posicionamiento de esta tesis

Capítulo 4

Metodología

En este capítulo se describe el marco metodológico de este trabajo de tesis.

4.1. El conjunto de datos MessIRve

MessIRve (Valentini et al., 2025b) es un conjunto de datos de gran escala creado para evaluar RI en español diseñado para satisfacer mejor las necesidades de hablantes de la lengua española en diferentes países. Cada instancia del conjunto de datos es un objeto tipo JSON que incluye un par de una consulta y un documento relevante que es un párrafo de la Wikipedia en español además de otros campos de metadatos. Para ver un ejemplo refiérase al listado 4.1.

Las consultas fueron obtenidas a partir de la API de autocompletado de Google, a partir de 120 prefijos semilla (“qué”, “cómo”, “dónde”, “quién”, ...). La API no siempre responde con consultas que empiezan estrictamente con los prefijos dados, y por tanto no todas las consultas comienzan con alguno de los prefijos. Los autores expandieron iterativamente el conjunto de prefijos basados en los resultados obtenidos por la API hasta obtener aproximadamente el número predefinido de consultas deseado. Las consultas así obtenidas están escritas en lenguaje natural y pueden contener errores gramaticales y ortográficos; por ejemplo, la consulta “porque se llama bogota” (¿por qué se llama Bogotá?) está incluida aunque le falten acentos, signos de interrogación, mayúscula, etc.

Los documentos en este conjunto de datos son párrafos de artículos de la Wikipedia en español en su extracto de abril del 2024.¹ En particular, los documentos relevantes son *featured snippets* de *Google Search* que enlazan a la Wikipedia en español. Los autores descartaron las consultas que no devolvieran *featured snippets* de la Wikipedia en español.

El proceso de extracción de consultas se realizó para 20 países con español como lengua oficial más Estados Unidos. Guinea Ecuatorial quedó excluida por no tener un dominio de Google. Además, en este proceso se encontraron consultas no específicas de algún país, a las que asignaron la etiqueta `no_country`. La unión de dichas consultas con las consultas de todos los demás países se denomina `full`. Las extracciones se realizaron entre marzo y junio de 2024, por lo que estas podrían reflejar los intereses populares de dicho periodo.

Las parejas consulta–documento además se dividieron en una partición de entrenamiento y otra de prueba de tal modo que el artículo de la Wikipedia al que pertenece cualquier párrafo relevante dado sea parte de solo una de las particiones: esto con el objetivo de reducir la intersección de tópicos entre los conjuntos de entrenamiento y prueba. El particionado se

¹Cada entrada en MessIRve contiene un campo `docid` de la forma `id_del_artículo#id_del_párrafo` como puede observarse en el listado 4.1.

Listado 4.1 · Ejemplo de una instancia del conjunto de datos MessIRve

```

1 {
2   "id": 7398356,
3   "query": "a cual movimiento literario pertenece fabio fiallo",
4   "docid": "129493#38",
5   "docid_text": "Ya en el siglo XX tenemos la figura de Fabio Fiallo, quien
   ↳ escribe cuentos modernistas influidos por su amigo Rubén Darío con "
   ↳ Cuentos frágiles" (1908), así como Tulio Manuel Cestero y Virginia
   ↳ Elena Ortea.",
6   "docid_title": "Literatura de la República Dominicana",
7   "query_date": "2024-03-28",
8   "answer_date": "2024-05-07",
9   "match_score": 1.0,
10  "expanded_search": false,
11  "answer_type": "feat_snip",
12  "id_country": 980799.0
13 }
```

realizó por país, asignando aproximadamente 20 % de los artículos al conjunto de prueba originalmente. En nuestros experimentos utilizamos únicamente el conjunto de prueba `full`, porque los autores de MessIRve solo reportaron sus experimentos en esta partición.

El conjunto de datos fue presentado oficialmente por los autores Valentini et al. (2025b) durante *The 2025 Conference on Empirical Methods in Natural Language Processing* de la *Association of Computational Linguistics* llevada a cabo del 4 al 5 de noviembre del 2025 en Suzhou, China. Los datos están disponibles en Hugging Face (Valentini et al., 2025a)² bajo la licencia Creative Commons BY-NC 4.0³. Para este proyecto utilizamos la versión 1.2 publicada en julio del 2025.

Consideramos que MessIRve es adecuado para esta tesis porque: (I) las consultas son textos reales escritos por hablantes nativos usando lenguaje natural, (II) las consultas y documentos son representativos de variantes dialectales de la lengua española en múltiples países que otros conjuntos de datos ignoran o no documentan y (III) MessIRve es el conjunto más grande de consultas y documentos no traducidos disponible durante la realización de este proyecto.

4.1.1. Estadísticas del conjunto de datos

El subconjunto `full` de MessIRve tiene, en su versión 1.2, 878 428 consultas únicas y 940 374 juicios de relevancia totales, distribuidos entre las particiones de entrenamiento y prueba. Refiérase a la tabla 4.1 para más detalles de su composición.

Los documentos, como explicamos antes, son párrafos de la Wikipedia en español de abril del 2024. Este corpus de documentos fue publicado por los autores de MessIRve y está disponible en Hugging Face (Valentini et al., 2024).⁴ El corpus consta de 14 047 759 párrafos de 1 946 205 artículos.

En MessIRve cada juicio contiene un campo llamado `match_score`: un número continuo en el intervalo $(0.5, 1]$ que denota la relevancia del documento dada la consulta. Nótese que

²<https://huggingface.co/datasets/spanish-ir/messirve>

³<https://creativecommons.org/licenses/by-nc/4.0/>

⁴https://huggingface.co/datasets/spanish-ir/eswiki_20240401_corpus

Partición	Consultas únicas	Documentos relevantes únicos	Artículos relevantes únicos	Filas (juicios)
Entrenamiento	708 373	119 336	45 158	766 296
Prueba	170 055	69 001	51 190	174 078
Total	878 428	188 337	96 348	940 374

Tabla 4.1: Estadísticas de las particiones del subconjunto `full` de MessIRve (versión 1.2). Las filas son juicios de relevancia (pares consulta–documento); las demás columnas son conteos de elementos únicos: un documento es un párrafo de la Wikipedia en español y un artículo es el artículo que lo contiene.

	Mínimo	Mediana	P95	P99	Máximo	Desviación estándar
Consultas (prueba)	3	5	9	12	22	1.88
Consultas (entrenamiento)	2	6	9	12	22	1.91
Documentos (prueba)	5	68	168	245	2 226	48.49
Documentos (entrenamiento)	5	64	170	252	2 101	51.04
Documentos (corpus)	5	47	153	233	9 757	49.51

Tabla 4.2: Longitud en palabras de las consultas y de los documentos. En los documentos, las palabras se cuentan sobre el título y el texto, igual que en el sistema de recuperación. Las consultas y los documentos relevantes provienen del subconjunto `full` de MessIRve (versión 1.2); el corpus, del volcado de la Wikipedia en español de abril de 2024.

en el subconjunto de prueba `match_score` es siempre 1; en otras palabras, el conjunto de prueba contiene únicamente documentos relevantes. Nosotros consideramos como irrelevantes los documentos que forman parte del extracto de la Wikipedia y que no fueron calificados como relevantes de esta forma.

Para conocer la distribución de la longitud de palabras de las consultas y documentos refiérase a la tabla 4.2. Observe que para los documentos contamos las palabras sobre el título y el texto: ésto es igual que en el sistema de recuperación que utilizamos en nuestros experimentos.

Una característica importante en la construcción de MessIRve es que la misma consulta puede tener diferentes respuestas inequívocas dependiendo del país en el que se pregunte. Así, por ejemplo, los autores incluyen la consulta “quién es el presidente” que tiene una respuesta bien definida en cada país. Una consecuencia de este hecho es que la misma consulta puede tener varios documentos relevantes en el subconjunto `full`.

En la tabla 4.3 podemos observar que alrededor del 98 % de las consultas tienen un solo documento relevante en la partición de prueba. Este hecho tiene consecuencias importantes en la elección de nuestra batería de métricas, como discutimos en el apartado 4.4.

Documentos relevantes	Entrenamiento		Prueba	
	Consultas	%	Consultas	%
1	656 785	92.72	166 201	97.73
2	46 036	6.50	3 698	2.17
3	4 862	0.69	143	0.08
4	611	0.09	13	0.01
5	67	0.01	—	—
6	10	<0.01	—	—
7	2	<0.01	—	—
Total	708 373	100	170 055	100

Tabla 4.3: Distribución del número de documentos relevantes por consulta. Los porcentajes se calculan sobre las consultas de cada partición del subconjunto `full` de MessIRve (versión 1.2); una consulta puede tener más de un documento relevante.

4.2. Sistema de recuperación

Para este proyecto creamos un sistema de recuperación de información con la arquitectura que mostramos en la figura 4.1 y que describimos a continuación:

1. Utilizando cada uno de los modelos base considerados obtenemos un *embedding* de cada documento en la base de datos `eswiki` y cada consulta de MessIRve.
2. Utilizamos Faiss ?? para hacer búsqueda exacta de

4.3. Algoritmos de fusión

4.4. Diseño experimental

4.4.1. Experimento 1: fusión vs. modelos individuales

4.4.2. Experimento 2: comparación de algoritmos de fusión

4.4.3. Experimento 3: fusión vs. reordenamiento neuronal

4.4.4. Experimento 4: modelos abiertos vs. propietarios




Figura 4.1: Arquitectura del sistema de recuperación. Los documentos provienen del corpus de la Wikipedia en español (eswiki) y las consultas y los documentos relevantes, del conjunto de datos MessIRve. La fusión de rangos y el reordenamiento neuronal se evalúan como alternativas sobre los candidatos del módulo de recuperación.

Capítulo 5

Resultados experimentales

En este capítulo se presentan y discuten los resultados experimentales obtenidos.

- 5.1. Experimento 1: fusión vs. modelos individuales
- 5.2. Experimento 2: comparación de algoritmos de fusión
- 5.3. Experimento 3: fusión vs. reordenamiento neuronal
- 5.4. Experimento 4: modelos abiertos vs. propietarios
- 5.5. Análisis de complementariedad léxico-semántica

Capítulo 6

Conclusiones y trabajo futuro

En este capítulo se presentan las conclusiones finales de este trabajo de tesis.

6.1. Conclusiones finales

6.2. Contribuciones del trabajo

6.3. Trabajo futuro

Bibliografía

- Valentini, F., Cotik, V., Furman, D., Bercovich, I., Altszyler, E., & Pérez, J. M. (2024). *eswiki_20240401_corpus* [Conjunto de datos]. Hugging Face. https://huggingface.co/datasets/spanish-ir/eswiki_20240401_corpus
- Valentini, F., Cotik, V., Furman, D., Bercovich, I., Altszyler, E., & Pérez, J. M. (2025a). *MessIRve* [Conjunto de datos] (Versión 1.2). Hugging Face. <https://huggingface.co/datasets/spanish-ir/messirve>
- Valentini, F., Cotik, V., Furman, D., Bercovich, I., Altszyler, E., & Pérez, J. M. (2025b). Messirve: A large-scale spanish information retrieval dataset. En C. Christodoulopoulos, T. Chakraborty, C. Rose & V. Peng (Eds.), *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing* (pp. 27740-27757). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2025.emnlp-main.1412>